

**ANKARA ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ
BÖLÜMÜ**



BLM 3522 PROJE RAPORU

Projenin Başlığı

Müşteri Kaybı (Churn) Tahmini ve Bulut

Üzerinde Model Dağıtımı

Öğrencinin Adı Soyadı

Erkim Berk

Ünsal

Öğrenci

Numarası

23291218

PROJE RAPORU

Müşteri Kaybı (Churn) Tahmini ve Bulut Üzerinde Model Dağıtımı

Ad Soyad	Erkim Berk Ünsal
Öğrenci Numarası	23291218
Ders	BLM3522 – Bulut Bilişim ve Uygulamaları
Proje No	Proje 3
Proje Konusu	Akıllı Veri Analitiği ve Makine Öğrenmesi Uygulaması
Tarih	15.06.2026
GitHub Deposu	https://github.com/erkimberk/BLM3522
Video Bağlantısı	https://youtu.be/6cUSm2Lu65I

1. Giriş

Bu projede, bir telekomünikasyon şirketinin müşteri verileri kullanılarak bir müşterinin abonelikten ayrılıp ayrılmayacağını (churn) tahmin eden bir makine öğrenmesi modeli geliştirilmiştir. Geliştirilen model yerel ortamda eğitilmiş, ardından Amazon Web Services (AWS) bulut platformu üzerinde Lambda servisine dağıtılarak bulut üzerinden tahmin yapabilen bir servise dönüştürülmüştür. Yapılan her tahmin ayrıca bir DynamoDB veritabanında saklanmaktadır.

Müşteri kaybı tahmini, gerçek iş dünyasında sıkça karşılaşılan ve veriden anlamlı bilgi çıkarmaya dayanan bir problemdir. Bir işletme, hangi müşterilerinin ayrılma riski taşıdığını önceden bilirse, bu müşterilere yönelik tutundurma çalışmaları yapabilir. Bu nedenle proje konusu hem teknik hem de pratik açıdan anlamlı bir örnek oluşturmaktadır.

Projenin temel amacı yalnızca bir model geliştirmek değil, bu modeli gerçek bir bulut ortamına taşımak ve orada çalıştırmaktır. Bu süreçte bulut bilişimin temel kavramları olan sunucusuz (serverless) mimari, kütüphane bağımlılık yönetimi ve bulut tabanlı veritabanı kullanımı uygulamalı olarak deneyimlenmiştir.

2. Kullanılan Teknolojiler

Proje boyunca aşağıdaki teknolojiler kullanılmıştır:

- Python 3: Model eğitimi ve tahmin kodunun yazıldığı programlama dili.
- Scikit-learn: Makine öğrenmesi modelinin (Lojistik Regresyon) eğitilmesinde kullanılan kütüphane.
- Pandas ve NumPy: Veri okuma, temizleme ve sayısal işlemler için kullanılan kütüphaneler.
- Joblib: Eğitilen modelin diske kaydedilmesi ve tekrar yüklenmesi için kullanılan araç.
- AWS Lambda: Modelin dağıtıldığı ve tahminlerin yapıldığı sunucusuz bilgi işlem servisi.
- AWS Lambda Layers: Modelin ihtiyaç duyduğu kütüphanelerin Lambda ortamına eklenmesini sağlayan katman yapısı.
- AWS S3: Kütüphane paketinin geçici olarak depolanması için kullanılan nesne depolama servisi.
- AWS CloudShell: Kütüphanelerin Linux uyumlu olarak hazırlandığı, tarayıcı tabanlı komut satırı ortamı.
- AWS DynamoDB: Yapılan tahminlerin saklandığı NoSQL veritabanı servisi.
- Git ve GitHub: Sürüm kontrolü ve projenin aşama aşama yayınlanması için kullanılmıştır.

3. Sistem Mimarisi

Sistemin genel işleyişi şu şekildedir: Veri seti yerel ortamda işlenir ve bir makine öğrenmesi modeli eğitilir. Eğitilen model, gerekli kütüphanelerle birlikte AWS Lambda servisine yüklenir. Lambda fonksiyonu, dışarıdan bir müşteri verisi aldığı anda modeli kullanarak bir tahmin üretir. Üretilen tahmin hem isteği yapan tarafa geri döndürülür, hem de DynamoDB veritabanına kalıcı olarak kaydedilir.

Bu mimarinin akışı aşağıdaki gibi özetlenebilir:

```
Veri Seti -> Model Eğitimi (yerel) -> AWS Lambda (model dağıtımı)
```

-> Bulut üzerinden tahmin -> DynamoDB (sonucun saklanması)

Sunucusuz (serverless) bir mimari tercih edilmesinin nedeni, sürekli açık bir sunucu çalıştırma maliyetinden kaçınmaktır. Lambda yalnızca bir istek geldiğinde çalışır ve yalnızca çalıştığı süre kadar kaynak tüketir. Bu yaklaşım, hem maliyet açısından verimli hem de bu projenin ölçeği için yeterlidir.

4. Veri Seti ve Keşif

Projede IBM Telco Customer Churn veri seti kullanılmıştır. Veri seti yaklaşık 7.000 müşteriye ait kayıt içermekte olup, her kayıt 21 farklı özellik barındırmaktadır. Bu özellikler arasında müşteriye ait demografik bilgiler (cinsiyet, yaşlı vatandaş olup olmama durumu), hizmet bilgileri (telefon, internet, online güvenlik, teknik destek), sözleşme tipi, ödeme yöntemi ve ücret bilgileri (aylık ücret, toplam ücret) yer almaktadır.

Hedef değişken, müşterinin hizmetten ayrılıp ayrılmadığını belirten Churn sütunudur. Veri seti incelendiğinde, 7.043 müşterinin 5.174 tanesinin hizmette kaldığı (No), 1.869 tanesinin ise ayrıldığı (Yes) görülmüştür. Bu, müşterilerin yaklaşık %27 oranında ayrıldığı anlamına gelir. Sınıf dağılımının dengesiz olması, model değerlendirmesinde yalnızca doğruluk (accuracy) değerine değil, kesinlik (precision) ve duyarlılık (recall) metriklerine de bakılmasını gerektirmiştir.

Keşif aşamasında dikkat çeken bir nokta, TotalCharges sütununun sayısal olması beklenirken metin tipinde okunmuş olmasıdır. Bu sütunun içinde, henüz toplam ücreti oluşmamış yeni müşterilere ait birkaç boşluk değer bulunmaktadır. Bu durum bir sonraki aşamada ele alınmıştır.

5. Veri Temizleme ve Ön İşleme

Modelin veriyi doğru şekilde işleyebilmesi için aşağıdaki ön işleme adımları uygulanmıştır:

- Her müşteriye özel bir kimlik olan customerID sütunu, tahmin açısından bilgi taşımadığı için veri setinden çıkarılmıştır.
- Metin olarak okunan TotalCharges sütunu sayısal tipe dönüştürülmüş, dönüştürülemeyen 11 adet geçersiz kayıt veri setinden çıkarılmıştır.
- Hedef değişken olan Churn sütunundaki Yes/No değerleri, modelin işleyebilmesi için 1 ve 0 olarak kodlanmıştır.
- Cinsiyet, sözleşme tipi, ödeme yöntemi gibi kategorik (metin) sütunlar, one-hot encoding yöntemiyle sayısal sütunlara dönüştürülmüştür.

Bu işlemler sonucunda veri seti, 7.032 satır ve 31 sütundan oluşan tamamen sayısal bir yapıya kavuşmuştur. Temizlenmiş veri, sonraki aşamada kullanılmak üzere ayrı bir dosyaya kaydedilmiştir.

6. Model Eğitimi ve Değerlendirme

Temizlenmiş veri seti, girdiler (X) ve hedef değişken (Churn) olarak ikiye ayrılmıştır. Ardından veri, %80 eğitim ve %20 test olacak şekilde bölünmüştür. Bu ayrım sayesinde model, eğitimde kullanılmayan bir veri kümesi üzerinde sınanmış ve gerçek performansı ölçülmüştür. Sonuçların tekrarlanabilir olması için sabit bir rastgelelik değeri (random_state) kullanılmıştır.

Model olarak Lojistik Regresyon (Logistic Regression) tercih edilmiştir. Bu yöntem, ikili sınıflandırma (evet/hayır) problemleri için yaygın, hızlı ve sonuçları yorumlanabilir bir algoritmadır. Müşterinin ayrılıp ayrılmayacağı da ikili bir sınıflandırma problemi olduğundan bu yöntem uygun bulunmuştur.

Model, test verisi üzerinde yaklaşık %79 (0,7875) doğruluk değerine ulaşmıştır. Aşağıdaki tabloda sınıf bazında elde edilen metrikler özetlenmektedir:

Sınıf	Kesinlik	Duyarlılık	F1-Skor
Kaldı (0)	0,83	0,89	0,86
Ayrıldı (1)	0,62	0,52	0,56

Sonuçlar incelendiğinde modelin, hizmette kalan müşterileri yüksek başarıyla tahmin ettiği (duyarlılık 0,89) görülmektedir. Ayrılan müşterilerin yakalanma oranı ise daha düşüktür (duyarlılık 0,52). Bunun temel nedeni, veri setindeki sınıf dengesizliğidir; ayrılan müşteri sayısı, kalan müşteri sayısının yaklaşık üçte biri kadardır. Karmaşıklık matrisine göre model, gerçekte ayrılan 374 müşterinin 193 tanesini doğru tahmin etmiştir. Genel olarak bu sonuç, churn tahmini problemleri için kabul edilebilir bir başlangıç performansı sayılmaktadır.

7. Modelin Kaydedilmesi

Eğitilen modelin bulut ortamına taşınabilmesi için diske kaydedilmesi gerekmiştir. Bu işlem için joblib kütüphanesi kullanılmıştır. Model, churn_model.pkl adlı bir dosyaya serileştirilerek kaydedilmiştir. Böylece model, her seferinde yeniden eğitilmek yerine doğrudan yüklenip tahmin için kullanılabilir hale gelmiştir.

Modelin yanı sıra, modelin beklediği girdi sütunlarının isim ve sırası da ayrı bir dosyaya (sutunlar.pkl) kaydedilmiştir. Bu liste, tahmin aşamasında gelen verinin doğru sütun sırasına yerleştirilmesi için gereklidir. Sütun sırasının karışması durumunda model yanlış tahmin üreteceğinden, bu adım önemlidir.

8. Tahmin Fonksiyonu ve Yerel Test

Bulutta çalışacak tahmin kodu, AWS Lambda'nın beklediği yapıda yazılmıştır. Kod içinde lambda_handler adlı bir fonksiyon bulunmakta olup, AWS her istek geldiğinde bu fonksiyonu çağırılmaktadır. Fonksiyonun işleyişi şu şekildedir: dışarıdan gelen müşteri verisi okunur, kaydedilen sütun sırasına göre düzenlenir, modele verilir ve tahmin sonucu (ayrılma durumu ve olasılığı) JSON formatında döndürülür.

Geliştirme sürecinde, kod doğrudan buluta yüklenmeden önce yerel ortamda test edilmiştir. Örnek bir müşteri profili (yeni, yüksek aylık ücretli, uzun süreli sözleşmesi olmayan ve fiber internet kullanan bir müşteri) ile fonksiyon çalıştırılmış ve doğru bir tahmin ürettiği doğrulanmıştır. Bu yaklaşım, hataların bulut ortamında değil, daha kolay müdahale edilebilen yerel ortamda yakalanmasını sağlamıştır.

9. AWS Lambda'ya Dağıtım

Projenin en kritik aşaması, modelin AWS Lambda servisine dağıtılmasıdır. Lambda, varsayılan olarak scikit-learn, numpy ve scipy gibi kütüphaneleri içermediğinden, bu kütüphanelerin bir Lambda Layer (katman) olarak hazırlanması gerekmiştir.

Katman hazırlama işlemi AWS CloudShell ortamında yapılmıştır. Kütüphaneler Linux uyumlu olacak şekilde kurulmuş, boyut sınırını aşmamak için gereksiz test ve önbellek dosyaları temizlenmiş, oluşturulan paket önce S3'e yüklenmiş ve oradan bir Lambda Layer olarak yayınlanmıştır. Model dosyaları ve tahmin kodu ise ayrı bir paket halinde Lambda fonksiyonuna yüklenmiştir.

Dağıtım aşamasında, gerçek bulut ortamlarına özgü çeşitli sorunlarla karşılaşmış ve bunlar çözülmüştür. Bu sorunlar ve çözümleri aşağıda özetlenmiştir:

- Kütüphane boyut sınırı: Hazırlanan paket, Lambda'nın açılmış paket boyutu sınırını (262 MB) aşmıştır. Gereksiz dosyaların temizlenmesi ve pandas bağımlılığının koddan kaldırılarak yalnızca NumPy kullanılmasıyla bu sınırın altına inilmiştir.
- Python sürüm uyumsuzluğu: Kütüphaneler Python 3.13 için derlenmişken Lambda fonksiyonu 3.12 olarak ayarlanmıştı. Bu durum bir NumPy içe aktarma hatasına yol açmış, fonksiyon Python 3.13 sürümüne geçirilerek sorun giderilmiştir.
- Eksik bağımlılıklar: Paket küçültülürken scikit-learn'ün ihtiyaç duyduğu bazı modüller (narwhals ve scipy.spatial.transform) yanlışlıkla silinmiştir. Bu modüller geri yüklenmiş ve yalnızca gerçekten gereksiz olan klasörler temizlenerek sorun çözülmüştür.

Tüm bu adımlardan sonra model bulutta başarıyla çalışır hale gelmiştir. Örnek müşteri verisi gönderildiğinde, fonksiyon 200 durum kodu ile yanıt vermiş ve müşterinin yaklaşık %68 olasılıkla ayrılacağını tahmin etmiştir. Bu sonuç, yerel ortamda elde edilen sonuçla birebir aynı çıkmış, böylece modelin buluta doğru şekilde taşındığı doğrulanmıştır.

10. Veritabanı Entegrasyonu (DynamoDB)

Projeye, yapılan her tahmini kalıcı olarak saklamak amacıyla bir AWS DynamoDB veritabanı eklenmiştir. Bu sayede sistem yalnızca tahmin üretmekle kalmamakta, ürettiği bilgiyi de saklayarak geçmişe yönelik sorgulamaya imkân tanımaktadır.

churn-tahminleri adında, talep başına ödeme (PAY_PER_REQUEST) modunda çalışan bir tablo oluşturulmuştur. Lambda fonksiyonu, her tahminden sonra bu tabloya bir kayıt eklemektedir. Her kayıta benzersiz bir kimlik numarası, tahminin yapıldığı zaman, gelen müşteri verisi, tahmin sonucu ve ayrılma olasılığı tutulmaktadır.

Veritabanı erişimi için gereken boto3 kütüphanesi AWS Lambda ortamında hazır geldiğinden, bu entegrasyon için ek bir kütüphane katmanı hazırlanmasına gerek kalmamıştır. Bir teknik ayrıntı olarak, DynamoDB ondalık sayıları Decimal tipinde sakladığından, ayrılma olasılığı değeri kayıt öncesinde bu tipe dönüştürülmüştür. Tablo içeriği, tarama (scan) işlemiyle sorgulanarak tahminlerin başarıyla kaydedildiği doğrulanmıştır.

11. Sürüm Kontrolü ve Geliştirme Süreci

Proje, baştan sona sürüm kontrolü altında, aşama aşama geliştirilmiştir. Her tamamlanan aşama GitHub deposuna ayrı bir commit olarak yüklenmiştir. Bu yaklaşım, projenin nasıl ilerlediğinin adım adım takip edilebilmesini sağlamaktadır. Başlıca aşamalar şunlardır: proje kurulumu, veri keşfi, veri temizleme, model eğitimi, modelin kaydedilmesi, tahmin fonksiyonunun yazılması, AWS Lambda'ya dağıtım ve DynamoDB entegrasyonu.

Bu çalışma biçimi, gerçek yazılım geliştirme süreçlerine benzer şekilde, küçük ve anlamlı adımlarla ilerlemeyi esas almıştır. Böylece herhangi bir aşamada sorun çıktığında, sorunun hangi değişiklikten kaynaklandığı kolayca tespit edilebilmiştir.

12. Sonuç ve Değerlendirme

Bu proje kapsamında, bir makine öğrenmesi modeli geliştirilmiş, bu model AWS Lambda üzerinde bulut ortamına dağıtılmış, bulut üzerinden tahmin alınmış ve elde edilen sonuçlar DynamoDB veritabanında saklanmıştır. Böylece ödevde belirtilen makine öğrenmesi modeli geliştirme, bulut üzerinde model dağıtımı ve veriden bilgi çıkarma hedeflerinin tamamı karşılanmıştır.

Proje sürecinde, yalnızca model geliştirmenin değil, bir modeli gerçek bir bulut ortamında çalışır hale getirmenin de kendine özgü zorlukları olduğu deneyimlenmiştir. Kütüphane boyut sınırları, sürüm uyumsuzlukları ve bağımlılık yönetimi gibi konular, bulut bilişimin uygulamalı tarafına dair önemli kazanımlar sağlamıştır. Bu yönüyle proje, teorik bilginin ötesinde pratik bir öğrenme deneyimi sunmuştur.

Geliştirilen sistem, mevcut haliyle bir başlangıç çözümü niteliğindedir ve çeşitli yönlerde geliştirilebilir. Örneğin, sınıf dengesizliğini gidermek için farklı yöntemler denenebilir, daha gelişmiş modeller (Random Forest, XGBoost gibi) kullanılabilir veya Lambda fonksiyonunun önüne bir API Gateway eklenerek servis dış dünyaya bir web servisi olarak açılabilir. Bu geliştirmeler, projenin gelecekteki olası adımları olarak değerlendirilebilir.